

## Les variables aléatoires multivariées

Souvent, nous nous intéressons à des statistiques avec plus d'une Variable.

## Définition

Une variable aléatoire multivariée est un vecteur de fonctions  $Z(\cdot) : \mathcal{S} \rightarrow \mathbb{R}^k$ ,  $k > 1$ .

Nous commencerons avec  $k = 2$  ou  $Z = (X, Y)$ ; on peut généraliser pour

$k > 2$  Points d'intérêts:

- ▶ La distribution jointe  $(X, Y)$ ;
- ▶ La distribution marginale de  $X$  et  $Y$ ;
- ▶ La distribution conditionnelle de  $X|Y$  et  $Y|X$ ;
- ▶ Leurs moments et transformations.

## Exemples

- ▶ Distribution jointes de l'âge et des années d'études, ou des salaires et de l'expérience
- ▶ Distribution conditionnelle des salaires par âge.
- ▶ Distribution marginale des salaires.

## Définition

La distribution jointe  $(X, Y)$  notée  $P_{X,Y}$  est :

$$P_{X,Y}(X, Y \in A),$$

Avec  $A \subseteq \mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$ . la fonction

$$f_{X,Y}(x, y) = P(X = x, Y = y)$$

Représente la PDF de  $(X, Y)$ .

En prenant  $A = (-\infty, x] \times (-\infty, y]$  on obtient la CDF jointe de  $(X, Y)$

$$F_{X,Y}(x, y) = P_{X,Y}(X \leq x, Y \leq y),$$

# La Distribution Jointe

De plus, en fonction de  $X$  et  $Y$ , l'a probabilité d'un évènement,  $A$

Dans  $\mathbf{R}^2$  est :

$$P_{X,Y}((X,Y) \in \mathcal{A}) = \sum_{(x,y) \in \mathcal{A}} f_{X,Y}(x,y) = \sum_{(x,y) \in \mathcal{A}} P_{X,Y}(X=x, Y=y),$$

$$\begin{aligned} P_{X,Y}((X,Y) \in \mathcal{A}) &= \int_{\mathcal{A}} f_{X,Y}(x,y) \, dx dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} 1_{\{(x,y) \in \mathcal{A}\}} f_{X,Y}(x,y) \, dx dy, \end{aligned}$$

avec  $f_{X,Y}(x,y) = \frac{\partial^2 F_{X,Y}(x,y)}{\partial x \partial y}$  Sous l'hypothèse de continuité.

# Exemple

Soit les probabilités jointes :

		$Y$			
		0	1	2	
$X$	0	.20	.05	.10	.35
	1	.10	.10	.05	.25
	2	.05	.20	.15	.40
		.35	.35	.30	1

On a ,  $P_{X,Y}(X=0, Y=0) = .20$ . on remarque que

$$F_{X,Y}(2,2) = \sum_{i=0,1,2} \sum_{j=0,1,2} P_{X,Y}(X=i, Y=j) = 1,$$

Toute fonction  $f(x, y)$  de telle sorte que  $f(x, y) \geq 0$  pour tout  $(x, y) \in \mathbb{R}^2$  et

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) \, dx \, dy = 1$$

Est la PDF jointe d'un vecteur bivarié

# La distribution marginale

La distribution marginale (maginal pdf) de (X,Y) en X=x est :

$$f_X(x) = \sum_y f_{X,Y}(x,y), \quad f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y) \, dy$$

La CDF marginale est :

$$F_X(a) = P_X(X \leq a) = \sum_{x \leq a} f_X(x), \quad F_X(a) = \int_{-\infty}^a f_X(x) \, dx$$

# Exemple

Les mêmes probabilités que plus haut

		$Y$			
		0	1	2	
$X$	0	.20	.05	.10	.35
	1	.10	.10	.05	.25
	2	.05	.20	.15	.40
		.35	.35	.30	1

Ici,

$$P_X(X=0) = \sum_{j=0,1,2} P_{X,Y}(X=0, Y=j) = .20 + .05 + .10 = .35$$

Et  $P_X(X=1) = .25$ ,  $P_X(X=2) = .40$ .

donc,

$$F_X(x) = \begin{cases} 0 & \text{if } -\infty < x < 0 \\ .35 & \text{if } 0 \leq x < 1 \\ .60 & \text{if } 1 \leq x < 2 \\ 1 & \text{if } 2 \leq x < \infty \end{cases}$$



Souvent, les valeurs des variables aléatoires sont corrélées : connaître la valeur que prend  $Y$  peut nous donner des informations sur la valeur que prend  $X$ , sauf si  $X$  et  $Y$  sont indépendants.

## Définition

Pour  $y$  tel que  $f_Y(y) > 0$ , la probabilité conditionnelle pmf/pdf de  $X$  sachant  $Y = y$  à  $x$  est notée  $f_{X|Y}(x|y)$  et vaut :

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

La CDF associée est :

$$F_{X|Y}(a|y) = \sum_{x \leq a} f_{X|Y}(x|y) = P(X \leq a | Y = y)$$
$$F_{X|Y}(a|y) = \int_{-\infty}^a f_{X|Y}(x|y) \, dx$$

# Exemple

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

Toujours les mêmes probabilités :

		$Y$			
		0	1	2	
$X$	0	.20	.05	.10	.35
	1	.10	.10	.05	.25
	2	.05	.20	.15	.40
		.35	.35	.30	1

ici,

$$f_{X|Y}(0|0) = \frac{.20}{.35}, \quad f_{X|Y}(1|0) = \frac{.10}{.35}, \quad f_{X|Y}(2|0) = \frac{.05}{.35},$$

La somme fait toujours 1.

Les distributions jointes, conditionnelles et marginales ont les même moments que les distributions univariées.

Exemples: soit  $Z =$

$$Z = \begin{pmatrix} X \\ Y \end{pmatrix}$$

$$\mu_Z = E[Z] = E\left[\begin{pmatrix} X \\ Y \end{pmatrix}\right] = \begin{pmatrix} E[X] \\ E[Y] \end{pmatrix} = \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}$$

$$V[Z] = E[(Z - \mu_Z)(Z - \mu_Z)'] = E[ZZ'] - \mu_Z \mu_Z'$$

C'est-à-dire ,

$$\begin{pmatrix} E[XX] & E[XY] \\ E[YX] & E[YY] \end{pmatrix} - \begin{pmatrix} \mu_X \mu_X & \mu_X \mu_Y \\ \mu_Y \mu_X & \mu_Y \mu_Y \end{pmatrix},$$

On appelle ce terme la matrice des covariances :

La diagonales représentes les variances ; les valeurs non diagonales les **covariances**;

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$$

# La loi des espérances itérées

La moyenne conditionnelle de  $X$  sachant  $Y = y$  est

$$\mu_{X|Y=y} = E[X|Y=y] = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx$$

La Loi des espérances itérées nous donne :

$$\begin{aligned} E_Y [E[X|Y]] &= \int_{-\infty}^{+\infty} \left[ \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx \right] f_Y(y) dy \\ &= \int_{-\infty}^{+\infty} x \left[ \int_{-\infty}^{+\infty} f_{X,Y}(x,y) dy \right] dx \\ &= \int_{-\infty}^{+\infty} x [f_X(x)] dx = E[X] \end{aligned}$$

C'est un résultat fondamental.

[Details](#)

L'espérance de l'espérance conditionnelle de  $X$  sachant  $Y$  est l'espérance de  $X$ .

Pour toute fonction  $g$ :

$$E[g(X)] = E_Y [E[g(X)|Y]]$$

La loi de la variance totale nous donne la décomposition suivante :

$$V[X] = E[V[X/Y]] + V[E[X/Y]].$$

Le premier terme représente la variance de  $X$  sachant  $Y$  ; le second terme la variance de  $X$  dans chaque groupe.

[Details](#)

## Theoreme

Pour chaque fonction  $r(\cdot)$  sur  $S \rightarrow \mathbb{R}$ , une propriété fondamentale est

$$E[g(x)E[Y|X]] = E[g(x)Y]$$

Cela implique

$$E[g(X)Y|X] = g(X)E[Y|X]$$

et

$$E[Y + Z|X] = E[Y|X] + E[Z|X]$$

$$E[cY|X] = cE[Y|X]$$

## Exemple

$$f_{X,Y}(x,y) = \begin{cases} 6(x-y) & 0 \leq y \leq x \leq 1 \\ 0 & \text{elsewhere} \end{cases} \quad \text{and} \quad \begin{aligned} f_X(x) &= 3x^2 \\ f_Y(y) &= 3(y-1)^2 \end{aligned}$$

Il faut remarquer que

$$E[Y|X = x] = \int_{-\infty}^{+\infty} y f_{Y|X}(y|x) dy = \int_0^x y \left[ \frac{2(x-y)}{x^2} \right] dy = \frac{x}{3}.$$

En appliquant la LEI :

$$\begin{aligned} E[Y] &= E[E[Y|X]] = \int_{-\infty}^{+\infty} E[Y|x] f_X(x) dx \\ &= \int_0^1 E[Y|x] [3x^2] dx = \int_0^1 \frac{x}{3} [3x^2] dx = \left[ \frac{1}{4} x^4 \right]_0^1 = \frac{1}{4} \end{aligned}$$

Si l'on calcule la moyenne depuis la pdf marginale de Y :

$$E[Y] = \int_{-\infty}^{+\infty} y f_Y(y) dy = \int_0^1 y [3(y-1)^2] dy = \left[ \frac{3}{4} y^4 - 2y^3 + \frac{3}{2} y^2 \right]_0^1 = \frac{1}{4},$$

.....

Si  $X$  et  $Y$  deux r.v. alors :

$$V[X + Y] = V[X] + V[Y] + 2\text{Cov}(X, Y)$$

$$V[X - Y] = V[X] + V[Y] - 2\text{Cov}(X, Y)$$

Pour une matrice  $A$ ,

$$V[AX] = A V[X] A^j$$

Pour des constantes,  $a, b, c, d$ ,

$$\text{Cov}(a + bX, c + dY) = bd \text{Cov}(X, Y)$$

À noter :  $\text{Cov}(X, X) = V[X]$ .



## Définition

$X$  et  $Y$  sont indépendants si

$$f_{X,Y}(x,y) = f_X(x) \times f_Y(y).$$

Cela implique  $f_{X|Y}(x|y) = f_X(x)$ .

EN pratique ,  $X$  et  $Y$  sont indépendants si connaître la distribution de l'un ne nous donne aucune information sur la distribution de l'autre .

Observation: (sans démonstration)

Si  $X$  et  $Y$  sont indépendants,  $g^1(X)$  et  $g^2(Y)$  aussi.

Si la PDF jointe de  $X$  et  $Y$  est une fonction de  $X$  et  $Y$  seulement,  $X$  et  $Y$  sont indépendants.

Si  $X$  et  $Y$  sont indépendants, alors  $E[XY] = E[X]E[Y]$

## Définition

L'indépendance de la moyenne :

$$E[X|Y = y] = E[X] \text{ pour tout } y$$

C'est une hypothèse plus faible mais qui implique par LIE :

$$E[g(Y)X] = E[g(Y)E[X|Y]] = E[g(Y)] E[X]$$

En particulier : soit  $U = X - E[X|Y]$  la déviation de  $X$  de sa moyenne conditionnelle, on a :

$$E[U|Y] = 0, \quad E[U] = 0, \quad E[YU] = 0,$$

Et donc  $\text{Cov}(Y, U) = 0$ .

C'est un concept plus faible que l'indépendance, l'indépendance l'implique mais pas la réciproque. De même ce n'est pas parce que  $X$  est m-indépendant par rapport à  $Y$  que  $Y$  l'est par rapport à  $X$ .

# Indépendance et Covariance

L'indépendance implique zéro covariance, la réciproque est fausse.

L'indépendance de la moyenne implique zéro covariance, la réciproque est fausse.

Si  $\text{Cov}(X, Y) = 0$ , alors

$$E[XY] = E[X]E[Y]$$

Par définition de la covariance.

## Exemple

Prenons  $Y = X^2$ . évidemment,  $Y$  et  $X$  sont dépendants. Cependant, si  $E[X] = 0$  and  $E[X^3] = 0$  (par Exemple si  $X$  suit une loi normale), alors :

$$\text{Cov}(X, X^2) = E[X^3] - E[X] E[X^2] = 0.$$

Le signe de la covariance nous indique dans quel sens les variables seront proportionnelles, sa magnitude dans quelle ampleur, mais elle est difficile à interpréter, c'est pourquoi on préférera utiliser la corrélation.

Il s'agit d'une normalisation utile de la covariance

## Définition

La corrélation se définit par :

$$\begin{aligned}\rho_{X,Y} &= E \left[ \left( \frac{X - E[X]}{\sigma_X} \right) \left( \frac{Y - E[Y]}{\sigma_Y} \right) \right] \\ &= \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E[XY] - E[X]E[Y]}{\sigma_X \sigma_Y}.\end{aligned}$$

L'avantage est que l'analyse dimensionnelle de la corrélation vaut 1, elle ne dépend pas de l'unité de X et Y et donne une relation linéaire entre les deux

Exemple:

si  $Y = a + bX$ , then

$$\rho_{X,Y} = \frac{b\sigma_X^2}{|b|\sigma_X\sigma_X} = \begin{cases} -1 & \text{if } b < 0 \\ 0 & \text{if } b = 0 \\ 1 & \text{if } b > 0 \end{cases} = \text{sign } b$$

## Théorème

L'inégalité de Cauchy Schwartz énonce :

$$E[(XY)]^2 \leq E[X^2] E[Y^2].$$

Tout d'abord :

$$0 \leq E[(cX + Y)^2] = c^2 E[X^2] + 2c E[XY] + E[Y^2].$$

En prenant  $c = E[XY] / E[X^2]$ , on retrouve le

résultat .

CS peut aussi s'écrire :  $Cov(X,Y)^2 \leq V(X)V(Y)$

Grace à cette inégalité on sait que la corrélation est bornée :

$$|\rho_{X,Y}| \leq 1$$

En prenant  $X - \mu_X$  et  $Y - \mu_Y$ , on obtient :

$$\begin{aligned} E[(X - \mu_X)(Y - \mu_Y)]^2 &\leq E[(X - \mu_X)]^2 E[(Y - \mu_Y)]^2 \\ \frac{E[(X - \mu_X)(Y - \mu_Y)]^2}{E[(X - \mu_X)]^2 E[(Y - \mu_Y)]^2} &\leq 1 \\ \frac{\text{Cov}(X, Y)^2}{\sigma_X \sigma_Y} &\leq 1 \\ \rho_{X,Y}^2 &\leq 1 \end{aligned}$$

# L'erreur quadratique moyenne [MSE]

On souhaite prédire  $X$ , si l'on postule que  $X$  vaudra  $c$ , le carré de l'erreur associé sera donc  $(X - c)^2$ .

## definition

Soit  $c$  une prédiction de  $X$ . la MSE pour  $c$  sera  $E[(X - c)^2]$ .

De plus,

$$E[(X - c)^2] = E[(X - \mu_X)^2] + (\mu_X - c)^2,$$

Cela équivaut à la somme de la variance et du Biais au carré.

le **biais** est un estimateur de la distance entre l'espérance de  $X$  et  $c$ .

La moyenne minimise la MSE. C'est donc le **meilleur prédicteur** de  $X$  selon l'erreur quadratique

Le meilleur prédicteur selon l'erreur absolue résous :

$$\underset{c}{\operatorname{argmin}} E[|X - c|]$$

Il s'agit de la médiane.

Le meilleurs prédicteur de  $X$  sachant  $Y = y$  (au sens MSE) est

$$\arg \min_c E[(X - c)^2 | Y = y] = \mu_{X|Y=y} = E[X|Y]$$

Par LIE :

$$E[(X - E[X|Y])^2] \leq E[(X - c(Y))^2]$$

Pour toute fonction  $c$   $c(\cdot)$ .

L'espérance conditionnelle est le meilleur prédicteur de  $X|Y$  au sens MSE.

Ce théorème sert de fondement à l'analyse par régression. Dans le cadre d'une régression paramétrique, on explique une variable indépendante  $Y$  par un vecteur  $X$  de variables explicatives (ou indépendantes) selon un modèle de type  $Y = g(X; \theta_0) + U$ , où  $g(X; \theta)$  est une fonction de  $x$  et  $\theta$  un vecteur de paramètres,  $U$  représente le terme d'erreur, que l'on suppose répondre à la condition  $E[U|X] = 0$ . Le problème est donc d'estimer le vecteur des paramètres :  $\theta_0$ .



# Le meilleurs prédicteur linéaire

Connaissant des variables aléatoires  $X$ ,  $Y$ , on souhaite prédire  $Y$  depuis  $X$ . Sauf cas particulier, l'espérance conditionnelle peut être une fonction compliquée à définir  $E[Y|X]$  on va donc chercher à l'approximer par une fonction de la forme  $Y = \alpha + \beta X$ .

Le meilleurs prédicteur linéaire de  $Y$  est le prédicteur minimisant la MSE .

Il résout  $\arg \min_{\gamma} E[(Y - (\alpha - \beta X))^2]$

Et vaut :

$$\tilde{\beta} = \frac{E[XY] - E[X]E[Y]}{E[X^2] - E[X]^2}$$

$$\tilde{\alpha} = \mu_Y - \tilde{\beta}\mu_X$$

Un estimateur commun du meilleurs prédicteur linéaire est l'OLS

## Annexes

Le théorème de la variance totale peut être démontré en utilisant la formule des espérances totales<sup>4</sup>. Tout d'abord

$$\text{Var}[Y] = E[Y^2] - [E[Y]]^2$$

par définition de la variance. On applique ensuite la formule des espérances totales à chaque terme en conditionnant par la variable aléatoire  $X$

$$= E[E[Y^2 | X]] - [E[E[Y | X]]]^2$$

On réécrit alors le moment conditionnel d'ordre 2 de  $Y$  en termes de sa variance et de son moment d'ordre 1 :

$$= E[\text{Var}[Y | X] + [E[Y | X]]^2] - [E[E[Y | X]]]^2$$

Puisque l'espérance est linéaire, les termes peuvent être regroupés :

$$= E[\text{Var}[Y | X]] + (E[[E[Y | X]]^2] - [E[E[Y | X]]]^2)$$

Finalement, les termes entre parenthèses peuvent être vus comme la variance de l'espérance conditionnelle  $E[Y|X]$  :

$$= E[\text{Var}[Y | X]] + \text{Var}[E[Y | X]]$$

$$g(y) = E[X|Y] = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) \, dx$$

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} \Rightarrow f_{X|Y}(x|y)f_Y(y) = f_{X,Y}(x,y)$$

$$\begin{aligned} E_Y [E[X|Y]] &= E_Y [g(y)] = \int_{-\infty}^{+\infty} g(y) f_Y(y) dy \\ &= \int_{-\infty}^{+\infty} \left[ \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) \, dx \right] f_Y(y) \, dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) f_Y(y) dx dy \\ &= \int_{-\infty}^{+\infty} x \left[ \int_{-\infty}^{+\infty} f_{X,Y}(x,y) \, dy \right] dx \\ &= \int_{-\infty}^{+\infty} x [f_X(x)] \, dx \\ &= E[X] \end{aligned}$$