


Les régressions linéaires

Quelques variantes

- Tenir compte de la non linéarité
- La régression linéaire pas toujours adaptée à la nature de la relation qui lie x et y
 - cf. forme du nuage de points
 - Ex : Cas où l'impact de x sur y dépend de la valeur initiale de x
 - Ex: Envisager une relation linéaire entre le niveau d'éducation et le taux de salaire suppose que les rendements marginaux de l'éducation sont constants.
 - Ex: Quel que soit le niveau d'éducation initial, une année supplémentaire augmentera toujours le salaire de la même somme.
- Le raccourci de la relation linéaire peut amener à une mauvaise interprétation.

- Tenir compte de la non linéarité :



Parfois, la relation entre y et x est non-linéaire


L'application des MCO génère

- un ajustement imparfait (SCR élevée)
- de l'hétéroscédasticité
- des prédictions fausses

On peut vouloir linéariser la relation entre y et x , en modifiant l'échelle de x ou de y (changement de variable)



- Tenir compte de la non linéarité :

Les changements de variables usuels : logarithme naturel ou puissance



- Tenir compte de la non linéarité

Les changements de variables usuels : logarithme naturel ou puissance



- Linéariser une relation
- Ex : la théorie quantitative de la monnaie
 - Équation théorique : $Mv=PQ$
 - Dévient une fonction affine en passant par Ln !
 $\text{Ln}(PQ)=\text{Ln}(M)+\text{Ln}(v)$
- Ex : la fonction Cobb-Douglas
 - Équation théorique : $Y = A K^{\alpha} L^{\beta}$
 - Dévient une fonction affine en passant par Ln !
 - $\text{Ln}(Y) = \text{Ln}(A) + \alpha \text{Ln}(K) + \beta \text{Ln}(L)$

- Transformation Log
- Envisager les évolutions en termes de pourcentages avec une transformation logarithmique des y et/ou x.
- Quatre combinaisons de formes fonctionnelles selon que la variation soit sous sa forme en « niveau » ou en log.
 - Le modèle « niveau-niveau », sans transformation
 - Le modèle « log-niveau »
 - Le modèle « log-log »
 - Le modèle « niveau-log »
- Les modèles "log-niveau" et "log-log" sont les plus utilisés en économie.

- Rappel sur l'élasticité :
- Définition : l'élasticité de y par rapport à x est le pourcentage de variation de y lorsque x varie de 1%.

$$\varepsilon_{y/x} = \frac{\% \Delta y}{\% \Delta x} = \frac{\partial y / y}{\partial x / x}$$

Ex: les élasticités prix et revenu en microéconomie

- Le modèle log-niveau ou semi-élasticité
- Le modèle s'écrit : $\log(y) = \beta_0 + \beta_1 x + u$
- Interprétation du β_1
 - β : mesure le taux de variation de y lorsque x varie de 1 unité.
 - Lorsque x varie d'1 unité, y varie de $(100 \cdot \beta)\%$.
 - $100 \cdot \beta$: semi-élasticité de y par rapport à x .
- Remarques : modèle souvent utilisé quand X est une variation de temps.

- Le modèle log-log ou modèle à élasticité constante
- Le modèle s'écrit : $\log(y) = \beta_0 + \beta_1 \cdot \log(x) + u$
- Interprétation de β :
 - β_1 mesure le taux de variation de y lorsque x varie de 1%.
 - Lorsque x varie d'1% , y varie de β_1 %.
- Remarques :
 - Très utilisé pour décrire de nombreux phénomènes.
 - Microéconomiques: Salaire=f(chiffre d'affaire) ou Ventes=f(dépenses en publicités)
 - Macroéconomiques : Densité médicale=f(population) ou PIB=f(impôts)

- Exemples:
- Soit le modèle estimé:

$$\log(\textit{salaire}) = 1.1157 + 0.0933 \cdot \textit{education}$$

- Le rendement de l'éducation: le salaire horaire augmente de 9.33% pour chaque année supplémentaire d'étude (ceteris paribus).
- L'effet de l'éducation sur le salaire est constant mais ce n'est plus une variation en euros, c'est une variation en % du salaire
- L'interprétation de la constante informe sur le log du salaire lorsque le niveau d'instruction est nul (pas très utile..)

- Exemples:
- Soit le modèle estimé:

$$\log(demande) = 4,7 - 1,25 \cdot \log(prix)$$

- L'élasticité-prix est de -1.25 : une augmentation de 10% du prix de vente engendre une baisse 12,5% de la quantité demandée.

- Soit le modèle estimé:

$$\log(consommation) = -6,6 + 1,27 \cdot \log(revenu)$$

- L'élasticité-revenu est de +1.27 : une augmentation de 10% du revenu engendre une hausse 12,7% de la consommation.

- Remarques
- Les coefficients ont une interprétation en termes de %
- On ignore les unités de mesure car une élasticité divise une variation de y par y , les deux ayant la même unité on se retrouve sans unité
- Il faut que l'interprétation en pourcentages ait un sens.
- Les logs sont:
 - Souvent utilisés pour des montants (euros, dollars, etc.)
 - Moins souvent utilisés pour des variables en années (âge, nombre d'années d'étude, expérience, espérance de vie, etc.).
 - Pas utilisés si la variable est déjà en pourcentages (taux de chômage, taux de réussite, etc.)
- Si des valeurs ≤ 0 sont possibles, la transformation log n'est pas possible.

Les modèles log

Type de modèle	Variable dépendante	Variable explicative	Interprétation du coefficient β_1
Niveau-Niveau	y	x	$\Delta y = \beta_1 \Delta x$
Niveau-Log	y	Log(x)	$\Delta y = \left(\frac{\beta_1}{100} \right) \% \Delta x$
Log-Niveau	Log(y)	x	$\% \Delta y = (100\beta_1)\Delta x$
Log-Log	Log(y)	Log(x)	$\% \Delta y = \beta_1 \% \Delta x$

Source : J. Wooldridge (2009), *Introductory Econometrics. A Modern Approach*, South Western, 4^{ème} édition

Les modèles quadratiques

- Objectif : capturer des effets marginaux non constants (croissants ou décroissants).
- $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + u$

Interprétation :


- Le coefficient β_1 mesure l'effet partiel à partir de 0, i.e. l'effet du passage de $x=0$ à $x=1$.
- Ensuite, l'effet marginal d'un gain d'1 unité de x se calcule de la manière suivante :

$$\frac{d\hat{y}}{dx} = \widehat{\beta}_1 + 2 \cdot \widehat{\beta}_2 \cdot x$$

Polynôme du 2nd degré :

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x + \hat{\beta}_2 \cdot x^2$$

- Si $\hat{\beta}_2 > 0$: l'extremum est un minimum




- Si $\hat{\beta}_2 < 0$: l'extremum est un maximum



- Pour des variables expliquées non-négatives:
 - β_1 : est souvent positif et β_2 ; est négatif.
 - β_2 ; est souvent très petit (0.00...).
 - Changement de pente lorsque x varie.
 - Petits changements au fur et à mesure ...
 - Ce changement de pente est néanmoins important pour des grandes valeurs de X.
- Forme parabolique de la courbe quadratique
 - il existe une valeur de x pour laquelle l'effet de x sur y est nul.

Les modèles quadratiques

- Courbe quadratique avec $\beta_1 > 0$ et $\beta_2 < 0$.
 - Ex: courbe de Kuznet
- Avec un polynôme d'ordre 2...
 - On peut identifier un optimum (max. ou min.)



- Courbe quadratique avec $\beta_1 > 0$ et $\beta_2 < 0$.

Le **point de retournement de la courbe quadratique** est le maximum de la fonction : $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$:

$$\frac{d\hat{y}}{dx} = \hat{\beta}_1 + 2 \cdot \hat{\beta}_2 x^* = 0 \rightarrow x^* = \left| \frac{\hat{\beta}_1}{2\hat{\beta}_2} \right|$$

Les modèles quadratiques

	(1)	(2)
	y	y
x	-0.006 (-0.024)	$\hat{\beta}_1$ 2.753*** (16.971)
xsq		$\hat{\beta}_2$ -0.307*** (-17.422)
_cons	4.314* (3.386)	-0.284 (-0.892)
N	8	8
R-sq	0.000	0.984
rss	16.047	0.260
rmse	1.635	0.228

t statistics in parentheses

* p<0.05, ** p<0.01, *** p<0.001

L'ajustement quadratique est meilleur que l'ajustement linéaire.

On trouve l'optimum ainsi :

$$x_1^* = -2,753 / (2 \times -0,307) = 4,5$$

C'est un maximum, parce que la dérivée seconde d^2y/d^2x_1 est $\hat{\beta}_2$ qui est négatif !

- Exemple : Salaire = $\beta_0 + \beta_1 \text{expérience} + \beta_2 \text{expérience}^2 + u$
- Avec $\beta_1 > 0$ et $\beta_2 < 0$ le salaire commence par augmenter avec l'expérience mais de moins en moins vite, puis il pourra potentiellement diminuer à partir d'un certain nombre d'année
- Il est possible d'ajouter des formes quadratiques d'ordre supérieur mais c'est rarement utile en pratique.

- Conclusion/résumé :
- Une fonction quadratique permet de mesurer des effets marginaux croissants et décroissants.
- Un test t est utilisé pour voir si le terme quadratique est statistiquement significatif.

Le modèle de régression linéaire avec information qualitative

Inclure une variable indicatrice

- ou binaire, dichotomique, dummy
- La variable prend la valeur de 0 ou de 1 selon la survenance ou non d'un évènement/caractère
- Conseil : nommer la variable de façon à indiquer l'évènement/caractère associé à la valeur unitaire.
 - Ex : la variable indicatrice dénommée "femme" prend la valeur 1 si l'individu est une femme, 0 sinon.
- On inclut directement la dummy dans le modèle
 - La référence d'interprétation est 0

Inclure une variable indicatrice

- Cas d'une variable qualitative nominale
 - ex : statut matrimonial (célibataire/marié/veuf/divorcé)
 - ex : statut dans l'emploi (actif/chômeur/retraité)
- On introduit plusieurs indicatrices : une pour chaque modalité
- !!! on omet une des modalités, pour éviter la colinéarité parfaite (information redondante, "trappe à indicatrices", qui servira donc de référence, R le fait automatiquement pour les variables de type facteur)
 - On construit $g-1$ dummies si la variable possède g modalités.
 - Interprétation : la modalité omise devient la référence.

- Combinaison de 2 variables binaires
- Combiner l'information de 2 variables binaires, pour créer une variable catégorielle à 4 modalités.
 - Ex : combiner l'information de la variable "marié" (0=pas marié) avec l'information de la variable "femme" (0=homme).
 - La variable correspondante comprend 4 catégories : les hommes mariés, les femmes mariées, les hommes non mariés, les femmes non mariées.
- Idem : on introduit une indicatrice pour chaque modalité, en omettant une des modalités, qui sera la référence

Inclure une variable ordinale

- Cas d'un variable qualitative ordinale, 2 possibilités:
- On peut l'intégrer directement dans le modèle
 - Ex: les tranches d'âges, les tranches de revenus
- Ou bien : on crée autant de variables indicatrices que de modalités, en omettant une des modalités qui sera la référence.
 - Intérêt : l'impact du passage de l'une à l'autre catégorie n'est plus supposé constant.
 - Permet des catégories moins homogènes

Inclure une variable ordinale

- Cas d'un variable catégorielle ordinale
- Comment l'inclure ?
- Ex: une variable état de santé (bon, moyen, mauvais)

$$\log(Dsante) = 0,15 + 0,23 \cdot ES_{moyen} + 0,37 \cdot ES_{mauvais}$$

- Un individu ayant un état de santé moyen (resp. mauvais) aura une dépense de santé annuelle supérieur de 23% (resp. 37%) à celle d'un individu ayant un bon état de santé (la référence).

- L'estimateur des MCO est une variable aléatoire
 - Donc sa distribution est soumise à une loi de probabilité
- Connaître la distribution de l'estimateur permet de faire des tests statistiques, de déterminer les intervalles de confiance
- ! On ne connaît la loi de distribution de β
- Comment déterminer cette loi ?

- Empiriquement
 - On dispose d'un échantillon,
 - On créer 1000 sous-échantillons aléatoires,
 - On procède à 1000 régressions,
 - Déterminer la loi qui s'en rapproche le plus,
 - Déterminer l'intervalle de confiance
- Techniques de ré-échantillonnage, quand on n'a pas d'idée sur la loi de β
- Simulation de Monte-Carlo, Bootstrap, Jackknife, permutations etc.
- Lourd à mettre en œuvre, mais on a vu la procédure sur R (inférence)

- Théoriquement
 - On a une idée sur la loi des β
 - On suppose que β suit une loi Normale
 - Cela revient à supposer que les erreurs suivent une loi Normale (hypothèse de l'OLS)
 - La normalité des termes d'erreur se translate directement à l'estimateur

$$u \sim N(0, \sigma^2)$$

- Hypothèse de Normalité $u \sim N(0, \sigma^2)$
 - Implication : $E(u)=0$ et homoscélasticite
 - On dit les erreurs sont i.i.d. indépendantes et identiquement distribuées
 - Conséquence : estimateur MCO de variance minimale parmi les estimateurs sans biais
 - Hypothèse forte, indispensable pour effectuer des tests paramétriques
 - Rend le modèle paramétrique
 - Permet l'inférence
 - Crédibilité ?

- En faveur de la normalité ...
- TCL + LDGN
- Cette hypothèse est «vraisemblable» avec n assez grand
=> convergence asymptotique
- L'hypothèse de Normalité des erreurs est communément admise dès lors que
 - Le nombre d'observations est suffisamment grand
 - La forme fonctionnelle est adaptée

- Si on connaît $\sigma^2_{\beta_j}$, pour chaque paramètre on a :

$$\frac{\hat{\beta}_j - \beta}{\sigma_{\beta_j}} \sim N(0,1)$$

Les coefficients sont dits centrés-réduits
ou « z-scores » dans les sorties de logiciels

- Si on ne connaît pas σ^2 : estimation des variances des estimateurs
 - Sauf dans les rares cas où σ^2 est observable, la variance de l'estimateur doit être estimée.
 - Nous utilisons l'estimateur de σ^2 ,

$$\sqrt{\widehat{V(\hat{\beta}_1)}} \rightarrow \hat{\sigma}_{\hat{\beta}_1}$$

- Loi suivie par les estimateurs MCO

Qui suit une distribution de Student qui permet de calculer un intervalle de confiance

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim T_{N-2}$$

Test d'hypothèse de nullité du coefficient

Estimation par intervalles de confiance :

- Remarques :
 - Par construction β_1 : se situe dans IC.
 - L'IC va nous informer sur la précision de notre estimation : elle sera d'autant plus précise que l'IC est étroit.
 - Si la valeur 0 ne fait pas partie de l'IC 95% nous pouvons rejeter l'hypothèse selon laquelle la variable x n'a pas d'impact sur y , au seuil de 5%. x a donc un impact significatif sur y . La variable x est pertinente.

Test d'hypothèse de nullité du coefficient

- C'est un test de conformité par rapport à une norme
- On veut tester l'hypothèse que la variable explicative x n'a pas d'impact sur y (H_0)
- Objectif :
 - x est-elle une variable pertinente pour expliquer y ?
 - le paramètre β_1 est-il significatif ?
- !!!! Attention : nous testons une hypothèse relative aux paramètres de la population,
 - et non relative à des estimations particulières pour un échantillon donné.
 - !!! nous ne testons PAS : $H_0: \beta_1 = 0$.